

INFORME DE LA SOLUCIÓN · DATA SCIENCE

Prevención de fraude orientada a ganancia

78,9%

de la ganancia ideal (**63,4% aprobando todo**)

+232 mil sobre 150.000 transacciones de 45 días · un modelo que estima el riesgo y una política que decide con el costo de cada error



Juanfe Martínez

DATA SCIENCE · MACHINE LEARNING · PREVENCIÓN DE FRAUDE

Dataset · 150.000 transacciones

Código · github.com/JuanFeDS/proyecto

Cada decisión tiene un costo: aprobar un fraude o rechazar una venta

Introducción

El objetivo es construir un **modelo que prediga si una transacción es fraudulenta** y usarlo para decidir de forma que se **maximice la ganancia** de la empresa. Para entrenarlo y evaluarlo se cuenta con **150.000 transacciones etiquetadas** (8 de marzo al 21 de abril de 2020, 5% de fraude). Resultado de cada decisión:

DECISIÓN	TRANSACCIÓN LEGÍTIMA	TRANSACCIÓN FRAUDULENTA
Aprobar	+25% del monto	-100% del monto
Rechazar	0 · se pierde la venta	0 · se evita la pérdida

Aprobar un fraude cuesta cuatro veces lo que deja una venta legítima del mismo monto. Por eso se evalúa con **ganancia**, como porcentaje de la **ganancia ideal** (aprobar todas las legítimas y ningún fraude), y no con accuracy: aprobar todo acierta el 95% y deja pasar 547 mil en fraude. La solución tiene dos piezas: un **modelo** que estima $P(\text{fraude})$ y una **política** que rechaza cuando esa probabilidad supera un umbral elegido según el costo. Montos en la unidad monetaria del dataset.

Hipótesis y desarrollo

Seis hipótesis de negocio sobre el fraude en pagos online guiaron el análisis y la construcción del modelo:

#	HIPÓTESIS	RESULTADO
H1	Acertar más no es ganar más: el umbral de rechazo debería estar muy por debajo del 50%	PREMISA Se deduce de los costos: corte teórico 20%. Con 50%, 4,7 puntos menos
H2	El fraude busca montos altos	CONFIRMADA El 20% más caro tiene 7,3% de fraude (4–5% el resto) y el 82% de la pérdida, con el 67% del volumen
H3	Menos historial, más fraude	CON MATICES En f l m el cuartil más bajo triplica el fraude; en d e h , menos. Que sean historial es una interpretación
H4	El fraude tiene horarios	CONFIRMADA 0–4 h: 10% a 17% de fraude, con el 3,2% del volumen; quitar hora cuesta 0,26 puntos
H5	El score de riesgo ayuda, pero no alcanza solo	CONFIRMADA Como regla única deja el 67,4%; el modelo que lo combina con el resto llega al 78,9%
H6	El fraude se repite por categoría (j , 8.324 categorías)	CON MATICES Hay señal, pero en su forma original el modelo la memorizaba

Hallazgo inesperado · fraude según el perfil o/n/p ("nulo" = sin dato; perfiles con ≥ 100 transacciones)




Figura 1 · De 1,1% a 35,7%: el dato vacío en **o** es la señal de menor riesgo.

De datos crudos a señales que no memorizan

150k

transacciones, 0 duplicados

5%

de fraude (7.500)

45 días

marzo-abril 2020

19columnas: 15 anonimizadas,
fecha, monto, score y
etiqueta

Hallazgos del análisis

5% exacto de fraude	→ probable muestreo: la tasa real puede exigir otro umbral
72,6% de datos vacíos en o	→ el vacío es información (en o, la señal de menor riesgo): no se imputa
País (g): 74% Brasil · 21% Argentina	→ países con 1 o 2 transacciones no permiten estimar su riesgo
Fraude diario entre 2,2% y 6,6%	→ el riesgo varía en el tiempo y hay que monitorearlo
Score: sin señales de filtración	→ relación gradual e imperfecta con el fraude; el resto de las variables explica solo el 16% de su valor

Transformaciones

Se construyeron 18 variables. Cada una se evaluó por su señal individual (con una variable aleatoria como piso de ruido) y por su aporte al modelo, comparando conjuntos fold a fold. El conjunto final agrega cuatro (el perfil o/n/p se descartó) y reemplaza a j y g crudas:

VARIABLE	CONSTRUCCIÓN	POR QUÉ
Tasa de fraude de j	Target encoding suavizado hacia la tasa global, calculado sin la etiqueta de la propia fila	Conserva la señal de j sin memorizar (H6)
Frecuencia de j	Transacciones de la categoría en entrenamiento	2,8% de fraude en categorías de 1 caso, 7,0% en las de más de mil
Perfil o/n/p	Combinación de las tres, con el vacío como categoría	AUC univariado 0,799, pero o ya lo captura: descartado
País agrupado	Países con menos de 100 transacciones → "Otros"	Evita tasas de países con 1 o 2 casos
Hora	Hora del día	Riesgo de la madrugada (H4); quitarla cuesta 0,26

Las otras 13 (ratios de historial, montos redondos, actividad reciente, día de la semana) no mejoraron el modelo: daban el mismo resultado con 33 variables en lugar de 20. La mejora grande es la tasa de j; hora y país aportan poco por separado, porque LightGBM ya combinaba las originales.

SIN LA PROPIA ETIQUETA (OUT-OF-FOLD)

En el pipeline final, las variables que resumen otras transacciones (tasa y frecuencia de j, países frecuentes) se aprenden solo con los folds de entrenamiento. Dentro de él, la tasa de j usa folds internos para que ninguna fila use su propia etiqueta: calculada de forma ingenua parecía mucho más fuerte (AUC univariado 0,783 frente a 0,645), y esa diferencia era memorización. Con folds aleatorios no es un cálculo temporal: una tasa puede usar etiquetas posteriores. Los vacíos no se imputan: LightGBM los trata de forma nativa.

Un cambio por vez, **contra una referencia**

Validación cruzada estratificada de 5 folds con predicciones out-of-fold; en cada configuración, el umbral se elige sobre la curva de ganancia. Cada etapa cambió un solo elemento y se comparó contra la anterior en los mismos folds, fold a fold.

ETAPA	RESULTADO (% DE LA GANANCIA IDEAL)
Referencias sin ML	Aprobar todo 63,4% · rechazar desde score 90 67,4%
Baseline	LightGBM por defecto, variables originales: 77,7%
Variables	Quitar j cruda y agregar las cinco transformaciones: 79,0% (+1,2 puntos, mejor en los 5 folds)
Algoritmos	Cinco algoritmos con esas variables y parámetros por defecto (figura 2)
Ajuste de hiperparámetros	Optuna, 50 combinaciones: +0,4 puntos medidos con folds nuevos (la búsqueda prometía +0,7)
Pesos por monto	No mejoran: con peso proporcional al monto la ganancia baja 0,5 puntos
Simplificación	Quitar el perfil o/n/p no cambia la ganancia (+0,1) y lleva el umbral óptimo al teórico, 0,20




Figura 2 · LightGBM, CatBoost y Random Forest empatan dentro de la variación entre folds.

Se eligió **LightGBM** por su desempeño equivalente, una validación 100 veces más rápida que CatBoost y manejo nativo de nulos y categóricas.

Solución final: modelo + política

Modelo	LightGBM ajustado (481 árboles, learning_rate 0,019, num_leaves 172, hojas de al menos 262 casos) que estima P(fraude) con 19 variables
Política	Rechazar si $P(\text{fraude}) \geq 0,20$, el umbral teórico, que coincide con el óptimo validado
Entrega	Pipeline único (variables + modelo + umbral) versionado en MLflow y servido por una API en Cloud Run

Medido en dinero, fuera de muestra

Todas las métricas se calculan con predicciones **out-of-fold**: cada transacción la evalúa un modelo que no la usó para aprender. El pipeline final (variables, modelo y umbral) se validó con cinco folds nuevos, distintos de los usados en el ajuste: **78,9% ± 1,3** de la ganancia ideal (ROC-AUC 0,889, PR-AUC 0,474).

Ganancia de cada alternativa




Figura 3 • +15,5 puntos sobre aprobar todo y +11,5 sobre la regla por score.

Decidir con el costo pesa más que el algoritmo

POLÍTICA ELEGIDA • UMBRAL 20%

78,9%

de la ganancia ideal

CORTE POR DEFECTO • 50%

74,2%

el de un clasificador: aprueba demasiados fraudes

DIFERENCIA

-4,7 puntos

con el mismo modelo




Figura 4 • El corte teórico, 20% ($0,25 \cdot m \cdot (1-p) = m \cdot p$; el monto se cancela), es también el óptimo: 78,9%.

Resultado en dinero

+232 mil

frente a aprobar todo, sobre 150.000 transacciones de 45 días (1.180 mil frente a 948 mil)

59%

del dinero en fraude evitado (325 de 547 mil), detectando el 48,5% de los fraudes

94,5%

de las transacciones aprobadas; 3% de las legítimas rechazadas

Robustez y supuestos

- **Calibración:** 31% predicho y observado en el decil más alto; cerca del umbral, 17% frente a 19% ponderando por monto.
- **Umbral:** frente a 15%, la diferencia no es significativa (+0,2, IC95 -0,3 a +0,7); por monto o país no mejora de forma concluyente.
- **Tiempo:** con solo el pasado, 73,7%, 77,1% y 79,5% en las 3 últimas semanas (-0,4 frente a la CV aleatoria); con ajuste y umbral del pasado, 80,0% en la última. En el tiempo, 15% habría ganado ~1 punto.

Detectar el fraude **que más cuesta**

La solución alcanza el **78,9% de la ganancia ideal**, frente al 63,4% de aprobar todo y al 67,4% de la regla basada en el score: **232 mil más** sobre las 150.000 transacciones evaluadas fuera de muestra, evitando el 59% del dinero perdido por fraude y aprobando el 94,5% de los pagos.

Qué explica el resultado

1 Medir en ganancia y decidir con el costo

Derivar el corte del costo vale 4,7 puntos frente al 50% por defecto de un clasificador; elegir entre los mejores algoritmos, 0,2.

2 Representar bien la historia de las categorías

La variable **j** cruda empeoraba el modelo; como tasa de fraude out-of-fold fue la mayor mejora.

3 Acotar el optimismo de la validación

Tuning medido con folds nuevos (+0,4 frente a +0,7 de la búsqueda) y modelo validado prediciendo semanas futuras: -0,4 puntos frente a la CV aleatoria.

Limitaciones

- **Variables anonimizadas:** las lecturas de negocio (historial, perfiles, país) son interpretaciones. El monto parece estar en una moneda común: su escala es similar entre países (mediana 18 en Brasil, 29 en Argentina).
- **Datos muestreados y atípicos:** 5% exacto de fraude y 45 días del inicio de la pandemia; la tasa real puede exigir reajustar el umbral.
- **Dependencia del score:** es la variable más valiosa (desordenarla cuesta 8,3 puntos) y la raíz de los errores más caros. Se asume disponible antes de decidir; sin ella, el baseline pierde 1,3 puntos.
- **Sesgo de selección y fricción:** si el dataset excluye lo que el sistema actual ya rechaza, el modelo no vio ese tráfico. Y la matriz de costos no mide la fricción de rechazar 4.612 compras legítimas (abandono, reclamos).

Próximos pasos

- Confirmar que el score está disponible al momento de decidir y ponerlo en producción en modo sombra.
- Recalibrar el umbral con etiquetas recientes (prediciendo el futuro, uno más bajo habría ganado ~1 punto) y monitorear el drift.
- En la franja cercana al umbral, revisar o pedir autenticación (3DS) en lugar de rechazar.
- Estudiar los fraudes con score medio, el principal punto ciego del modelo.

El valor no vino de un algoritmo en particular, sino de medir en dinero, decidir con el costo de cada error y medir el resultado sin la propia etiqueta de cada transacción.

CÓDIGO, NOTEBOOKS Y REPORTE EXTENDIDO • [GITHUB.COM/JUANFEDS/PROYECTO](https://github.com/JUANFEDS/PROYECTO)